

דוח מסכם

תיאור הדאטה והכנת הנתונים

בדאטה הגולמי היו כ- 133,885 רשומות ו-13 עמודות, שכללו מידע בסיסי על הסרטים: מזהה סידורי, שם הסרט, שנת יציאה, ז'אנרים, שחקנים ראשיים, אורך הסרט, דירוג ממוצע, שפה, מדינה, תקציב, הכנסות, מספר הצבעות ותקציר עלילה. לאחר שלב הניקוי והעיבוד התקבלה טבלת פיצ'רים בגודל 115,560 רשומות ו-261 עמודות. הירידה במספר השורות נבעה מהשארית סרטים בעלי משתנה מטרות תקין לטובת אימון נכון של המודל והעלייה במספר העמודות נבעה מהמרת עמודות גולמיות לפיצ'רים מתאימים למודל. בשלב העיבוד הוסרו עמודות שאסורות לשימוש במודל, הוסרו עמודות שהחלטנו שלא נרצה במודל ונבנו פיצ'רים חדשים מתוך העמודות הגולמיות.

בחרנו במודל Random Forest כמודל השני מהסיבות הבאות:

עמידות לנתונים חסרים ורועשים - הדאטה שלנו מכיל ערכים חסרים רבים (50-60% בחלק מהעמודות) Random Forest עמיד יותר לרעש בהשוואה למודלים לינאריים.

לכידת קשרים לא-לינאריים - הקשרים בין הפיצ'רים לבין דירוג הסרט אינו בהכרח לינארי Random Forest מסוגל ללכוד אינטראקציות מורכבות בין פיצ'רים.

טבלת הפיצ'רים:

פיצ'ר	אופן בנייה	מוטיבציה
decade	חישוב עשור יציאה לפי שנת הסרט: $\text{startYear} // 10 * 10$	סרטים מתקופות שונות מציגים דפוס דירוג שונים - תקופת הקולנוע הקלאסי לעומת הקולנוע המודרני
runtime_cat	חלוקת אורך הסרט לקטגוריות אורך	אורך הסרט עשוי להשפיע על חווית הצפייה ועל הדירוג - סרטים קצרים מדי או ארוכים מדי עלולים לקבל דירוג שונה
n_genres	ניקוי רשימת הז'אנרים וספירת מספר הז'אנרים לכל סרט	סרטים עם ז'אנרים מרובים עשויים לפנות לקהל רחב יותר ולקבל דירוג שונה מסרטים עם ז'אנר יחיד
genre_*	יצירת עמודות דגל עבור 15 ז'אנרים מרכזיים שנבחרו מראש	ז'אנר הסרט הוא מאפיין בסיסי שמאפיין את סוג הקהל, אופי התוכן וציפיות הצופים ולכן יש בסיס לשערה שז'אנרים שונים יקבלו דירוגים שונים בממוצע.
budget_reported	אם תקציב מדווח לסרט 1 אחרת 0	סרטים עם תקציב מדווח נוטים להיות הפקות מסחריות מתועדות אינדיקציה לרמת ההפקה
plot_length	ספירת מספר המילים בתקציר העלילה, ערך 0 כאשר אין תקציר	סרטים מתועדים היטב נוטים להיות מוכרים ופופולריים יותר
is_english	סימון האם אנגלית מופיעה כאחת משפות הסרט	סרטים באנגלית מגיעים לקהל רחב יותר מה שעשוי להשפיע על דפוס דירוג
country_clean	ניקוי ואיחוד וריאציות כתיבה של מדינות. לאחר מכן הקידוד מתבצע ב-Pipeline לפי נתוני האימון	מדינת הייצור קשורה לסגנון קולנועי ולקהל היעד ולכן לאחר ניקוי הרעש אפשר ללמוד דפוסים לפי מדינה
director_acclaimed	אם אחד הבמאים מופיע ברשימת במאים מוכרים 1 שהוגדרה מראש אחרת 0	לבדוק האם נוכחות במאי מוכר תורמת לחיזוי הדירוג
n_director	ספירת מספר הבמאים לכל סרט לפי קובץ title.crew.tsv	מספר הבמאים לסרט עשוי להצביע על אופי ההפקה
actor_acclaimed	אם אחד השחקנים מופיע ברשימת שחקנים מוכרים 1 שהוגדרה מראש אחרת 0	נוכחות שחקן מוכר עשויה למשוך קהל רחב יותר ולהשפיע על הדירוג
has_actors	אם קיים שחקן 1 אחרת 0	היעדר מידע על שחקנים אופייני לסרטים נישתיים או לא מתועדים אינדיקציה לרמת הנראות של הסרט בדאטה

תיעוד פונקציית prepare_data

פונקציית prepare_data מרכזת את הכנת הנתונים לפני המידול. מטרתה לקבל את הדאטה הגולמי, לבצע ניקוי בסיסי והנדסת פיצ'רים, להחזיר טבלת פיצ'רים מעובדת המתאימה להמשך עבודה בתוך Pipelinen.

במסגרת הפונקציה בוצעו השלבים הבאים:

1. יצירת עותק של הדאטה - נוצר עותק של הטבלה המקורית, כדי לא לשנות ישירות את הדאטה הגולמי. הסרת עמודות שאסורות במודל numVotes, BoxOffice.
 2. עיבוד שנה ואורך סרט - startYear הומר לערך מספרי ומתוכו נוצר decade. runtimeMinutes - הומר לערך מספרי ומתוכו נוצר runtime_cat, המחלק את הסרטים לקטגוריות אורך.
 3. עיבוד ז'אנרים - עמודות genres עברה ניקוי, פיצול לרשימת ז'אנרים וספירה ליצירת n_genres. בנוסף, נוצרו דגלים בינאריים עבור 15 ז'אנרים מרכזיים שנבחרו מראש לפי ידע חיצוני וכלי AI.
 4. עיבוד מדינה ושפה - עמודת Country עברה ניקוי ואיחוד וריאציות כתיבה שונות. מתוך Language נוצר is_english המציין האם הסרט כולל אנגלית כאחת השפות.
 5. עיבוד תקציב - מאחר שעמודות budget כללה חוסרים רבים ופורמטים לא אחידים, לא השתמשנו בסכום התקציב עצמו. עם זאת, לא רצינו לוותר על המידע לחלוטין, משום שעצם קיומו של תקציב מדווח עשוי להעיד על סרט מתועד, מוכר או ממוסד יותר. לכן יצרנו את budget_reported, פיצ'ר בינארי המציין האם קיים תקציב מדווח.
 6. עיבוד תקציר העלילה - מתוך plot נוצר plot_length, המודד את מספר המילים בתקציר. ערכים חסרים או לא אינפורמטיביים קיבלו ערך 0. הפיצ'ר אינו מודד את איכות העלילה, אלא את כמות המידע הזמין על הסרט.
 7. הוספת מידע על במאים ושחקנים - מאחר שבדאטה המקורי לא הופיעה עמודת שמות במאים, נוספה עמודת במאים באמצעות הצלבה לפי מזהה הסרט. עבור השחקנים נעשה שימוש בטבלת עזר שקישרה בין מזהי השחקנים לבין שמותיהם. לאחר מכן נוצרו director_acclaimed, actor_acclaimed, n_director וhas_actors.
 8. הסרת עמודות גולמיות לאחר העיבוד - לאחר יצירת הפיצ'רים החדשים הוסרו עמודות שאינן נדרשות עוד למודל, כגון מזהים, עמודות טקסט מקוריות ועמודות שכבר הומרו לפיצ'רים.
- בסיום הפונקציה מתקבלת טבלת פיצ'רים נקייה ועקבית יותר. פעולות שלומדות מהנתונים, כגון השלמת ערכים חסרים, Encoding וScaling, בוצעו בהמשך בתוך Pipelinen ולא בתוך prepare_data.

מניעת Data Leakage

כדי למנוע Data Leakage הפרדנו בין פעולות ניקוי דטרמיניסטיות שבוצעו בprepare_data לבין פעולות שלומדות מהנתונים ובוצעו רק בתוך Pipeline. prepare_data יצרה פיצ'רים שמחושבים לכל שורה לפי הערכים שלה בלבד, כגון is_english, budget_reported, plot_length, n_genres, decade, פיצ'ר ז'אנרים ופיצ'ר במאים ושחקנים. בנוסף averageRating נשמר כמשתנה המטרה בלבד, numVotes וBoxOffice הוסרו משום שהן זמינות רק לאחר יציאת הסרט.

בתוך Pipeline השתמשנו בColumnTransformer, שחילק את הפיצורים לפי סוגם : פיצורים נומריים עברו השלמת ערכים חסרים בחנו האם ניתן להשתמש ב-KNNImputer במקום SimpleImputer על הפיצורים הנומריים. בדיקת קורלציות בין החסרים (missingness heatmap) הראתה כי החסרים הם MAR ולא MCAR דבר שמצדיק שימוש ב KNN עם זאת, ניתוח הדאטה העלה שני מכשולים : ראשית, רק שלושה פיצורים נומריים קיימים (decade, n_genres, plot_length) מה שמגביל את יכולת KNN ללמוד מרחקים משמעותיים. שנית plot_length, הפיצור הנומרי העיקרי עם ערכים חסרים מכיל כ-52% ערכי 0, כמות חסרים גבוהה מדי שעלולה לפגוע באמינות ההשלמה. לכן הושאר SimpleImputer עם חציון כפתרון היציב יותר עבור הדאטה הנוכחי. פיצורים קטגוריאליים כמו runtime_cat וcountry_clean עברו השלמה לערך Unknown, לאחר מכן קידוד באמצעות OneHotEncoder פיצורים בינאריים הועברו כpassthrough. בקידוד הקטגוריאלי השתמשנו בmax_categories=15 ובhandle_unknown=ignore, כך שהקטגוריות המרכזיות נלמדו מנתוני האימון בלבד, ערכים חדשים בסט הבדיקה טופלו ללא התאמה מחדש של המודל.

בשלב בחירת ההיפרפרמטרים חילקנו את הדאטה ל-80% אימון ו-20% בדיקה. GridSearchCV הופעל על נתוני האימון בלבד (X_train, y_train) עם 10-fold CV פנימי, כך שנתוני הבדיקה לא נחשפו למודל בזמן בחירת הפרמטרים. לאחר מכן ביצענו הערכת ביצועים סופית באמצעות cross_validate עם 10 fold על כלל הדאטה (X, y). שלב זה היה נפרד מהGrid Search, ובכל fold ה-Pipeline הותאם מחדש רק על נתוני האימון של אותו fold.

השוואת המודלים לפי מדדי ביצועים

לצורך השוואת המודלים השתמשנו ב-10-fold Cross Validation. נבחנו שני מודלים : ElasticNet ו-Random Forest, באמצעות שלושת המדדים RMSE, MAE ו-R² (ראה נספח 1). כפי שניתן לראות בנספח 1 מודל Random Forest הציג ביצועים טובים יותר בכל המדדים : ערכי השגיאה שלו נמוכים יותר במדדי RMSE ו-MAE, וערך ה-R² שלו גבוה יותר. אף שהפערים אינם גדולים, הם עקביים, ולכן בחרנו ב-Random Forest כמודל המועדף להמשך הניתוח. יתרון זה מתאים לאופי המודל, המסוגל לזהות קשרים לא ליניאריים ואינטראקציות בין פיצורים, לעומת ElasticNet שהוא מודל ליניארי יותר.

ניתוח חשיבות פיצורים

בשלב זה בחנו אילו פיצורים תרמו ביותר לחיזוי הדירוג בכל אחד מהמודלים. עבור ElasticNet ניתחנו את מקדמי המודל : ערך חיובי מצביע על קשר לדירוג חזוי גבוה יותר, ערך שלילי מצביע על קשר לדירוג חזוי נמוך יותר.

עבור Random Forest ניתחנו את חשיבות הפיצורים לפי feature_importances_ המובנה של המודל, וכיוון ההשפעה הוערך באמצעות ערכי SHAP (TreeExplainer) (ראו נספח 2).

ElasticNet : הפיצורים המרכזיים הם genre_documentary ו-director_acclaimed עם השפעה חיובית, ו-genre_horror עם השפעה שלילית.

הופעת runtime_cat_long ו-genre_animation בין חמשת הפיצורים המובילים מצביעה על כך שסרטים ארוכים וסרטי אנימציה נוטים לדירוג גבוה יותר לפי המודל.

Random Forest : הפיצירים המרכזיים הם genre_documentary עם השפעה חיובית חזקה ו- genre_horror עם השפעה שלילית חזקה .

genre_drama ו- plot_length נקשרו להשפעה חיובית מתונה.

decade הציג השפעה מורכבת ולא לינארית -ערכי SHAP מפורזים לשני הכיוונים בהתאם לאינטראקציות עם פיצירים אחרים.

בהשוואה בין המודלים קיימת הסכמה חלקית : שניהם מזהים את genre_documentary כפיציר המשפיע ביותר ואת genre_horror כבעל השפעה שלילית חזקה. לצד זאת ElasticNet, כמודל לינארי מדגיש קשרים ישירים כמו director_acclaimed וז'אנרים ספציפיים, בעוד Random Forest מצליח ללכוד גם מאפיינים עקיפים כמו אורך התקציר ועשור היציאה דרך קשרים מורכבים ואינטראקציות בין פיצירים.

Eroor Analysis - ניתוח שגיאות

לאחר בחירת Random Forest כמודל המועדף, בחנו את עשרת מקרי Overprediction ועשרת מקרי Underprediction הקיצוניים ביותר. נמצא כי המודל מתקשה בעיקר בסרטים הנמצאים בקצוות התפלגות הדירוגים, דפוס התואם להתפלגות averageRating, שבה רוב הדוגמאות מרוכזות סביב הממוצע ובקצוות קיימות פחות דוגמאות אימון. לכן, במקרים חריגים, המודל נוטה לבצע רגרסיה לכיוון מרכז ההתפלגות.

לצורך ניתוח איכותני בחרנו חמישה סרטים מתוך טבלת השגיאות הקיצוניות. הטבלה שלהלן מציגה לכל סרט את סוג השגיאה, תיאור קצר, השערה לסיבת הטעות והמאפיין הייחודי שעשוי להסביר אותה.

סרט	סוג השגיאה	תיאור קצר	השערה לסיבת השגיאה ומה המודל אינו יודע	מאפיין ייחודי אפשרי
Justin Bieber: Always Believing	Overprediction	סרט תיעודי ביוגרפי על עלייתו של ג'סטין ביבר.	המודל זיהה את genre_documentary כפיציר חיובי, אך אינו יודע לזהות יחס ציבורי שלילי או קיטוב סביב הדמות המרכזית בסרט.	דמות ציבורית מוכרת שעשויה לעורר תגובות קהל קיצוניות.
Tribalism Is Killing Us	Overprediction	סרט תיעודי חברתי העוסק בקיטוב אידיאולוגי.	המודל פירש את הסרט כחיובי בגלל הז'אנר הדוקומנטרי וקיום תקציר, אך אינו מנתח את תוכן התקציר או מזהה נושא פוליטי טעון.	נושא חברתי-פוליטי שעשוי לעורר תגובות מקוטבות.
Justicia Implacable	Underprediction	דרמת נקמה בעולם התחתון.	הסרט קיבל דירוג אמיתי גבוה, אך מבחינת המודל הוא כמעט חסר מידע: ללא תקציב, ללא תקציר, מדינה לא מזוהה ושפה שאינה אנגלית.	ייתכן שמדובר בסרט מקומי או נישתי שהמודל אינו יודע להבחין בינו לבין סרט אנונימי עם מעט מידע.
Son-nim-1 Cheo-beon-jjae I-ya-gi	Underprediction	סרט אימה ומתח המתרחש סביב כפר מבודד ואירועים מסתוריים.	המודל זיהה ז'אנרים כמו Horror ו-Thriller, שנקשרו לתחזיות נמוכות יותר, בנוסף לחוסר במידע על מדינה, תקציב ותקציר.	סרט זר או נישתי שעשוי לפנות לקהל יעד נאמן, אך הקשר זה אינו מיוצג בפיצירים.
Bukunja Tekunja Mitti: The Cannibals	Underprediction	סרט פעולה ואימה על מאבק הישרדות מול שבט קניבלים.	מבחינת המודל הסרט נראה דל מידע: Action/Horror, ללא תקציב, מדינה או תקציר, ולכן נחזה נמוך מדי.	ייתכן שהדירוג הגבוה נובע מקהל נישתי או מתגובה לא שגרתית של קהל, מידע שאינו קיים בפיצירים.

בחינת כלל 20 השגיאות הקיצוניות מראה כי שתי הקבוצות מציגות פרופיל חסרים דומה מאוד : ברוב הסרטים חסרים נתוני מדינת מקור, שפה או תקציב מדווח. ממצא זה מצביע על כך שחוסר נתונים תורם לשגיאות בשני הכיוונים, אך אינו מסביר לבדו את כיוון השגיאה.

ההבדל המרכזי בין הקבוצות נובע מהפיצירים שהמודל כן הצליח לזהות. בקבוצת Overprediction בלט במיוחד genre_documentary, שהופיע ברוב הסרטים ונקשר במודל לתחזיות גבוהות יותר. לכן המודל

נטה להעלות את התחזית גם במקרים שבהם הדירוג האמיתי היה נמוך מאוד. לעומת זאת, בקבוצת Underprediction בלטו יותר ז'אנרים כמו Thriller Horror, Action, שנקשרו לתחזיות נמוכות יותר, אף שבפועל חלק מהסרטים קיבלו דירוגים גבוהים מאוד.

בנוסף, ראינו כי פיצ'רים כמו `plot_length` ו `has_actors` אינם מספיקים כדי לתקן את השגיאות. `has_actors` מציין רק האם קיים מידע על שחקנים, אך לא את מידת ההיכרות איתם או את התאמתם לקהל היעד. בדומה לכך, `plot_length` מודד את כמות הטקסט בתקציר, אך לא את איכות העלילה או את משמעותה.

לסיכום, השגיאות הקיצוניות משקפות מגבלה מבנית של הפיצ'רים הקיימים. במקרי Overprediction המודל מושפע ממאפיין חיובי שעלול להיות מטעה, בעיקר ז'אנר דוקומנטרי. במקרי Underprediction חסרים למודל פיצ'רים שמייצגים הצלחה נישתית, הקשר תרבותי או תגובת קהל חריגה.

השוואה בין שני המודלים -

המטרה לבדוק האם השגיאות נובעות מבחירת המודל או ממגבלות רחבות יותר של הדאטה והפיצ'רים. מההשוואה נמצא כי קיימת חפיפה משמעותית בין המודלים: בקבוצת Overprediction שני המודלים חולקים 6 מתוך 10 הסרטים בעלי השגיאה הגבוהה ביותר, ובקבוצת Underprediction הם חולקים 4 מתוך 10 סרטים. כלומר, חלק ניכר מהשגיאות הקיצוניות חוזרות בשני המודלים, בעיקר במקרים שבהם המודל חזה דירוג גבוה מדי.

ממצא זה מצביע על כך שהשגיאות אינן נובעות רק מאלגוריתם מסוים. כאשר מודל ליניארי ומודל לא ליניארי נכשלים בחלק מאותם סרטים, סביר שהבעיה קשורה למידע שהמודלים מקבלים: פיצ'רים חלקיים, ז'אנר דוקומנטרי שעלול להטעות את החיזוי, סרטים נישתיים או דירוגים שמושפעים מגורמים שאינם מיוצגים בפיצ'רים, כמו תגובת קהל חריגה או הקשר תרבותי.

בהשוואה נקודתית ElasticNet הציג שגיאות קטנות יותר בעיקר ב Shared Underpredictions (4 מתוך 4 מקרים), בעוד ב Unique Underpredictions - יצא תיקו (6/6) וב- Overpredictions ביצועי שני המודלים דומים. הפערים בין המודלים קטנים יחסית (0.3-0.6 נקודות), ולכן אין בכך כדי להצביע על יתרון מהותי של אחד המודלים במקרי הקיצון. מכאן שהשגיאות הקיצוניות אינן נפתרות על ידי החלפת מודל, אלא דורשות פיצ'רים עשירים יותר שיתארו טוב יותר קהל יעד, הקשר תרבותי ותגובות קהל חריגות.

הצעת פיצ'רים נוספים בעקבות ניתוח השגיאות

בעקבות ניתוח השגיאות הקיצוניות זיהינו שלושה כיוונים לפיצ'רים שיכולים לשפר את המודל, בעיקר עבור סרטים זרים או נישתיים שהמודל חזה להם דירוג נמוך מדי.

original_language_match - פיצ'ר בינארי הבדוק האם שפת הסרט תואמת למדינת המקור שלו, למשל קוריאנית ודרום קוריאנה, איטלקית ואיטליה או שפות הודיות והודו. המוטיבציה היא לזהות סרטים מקומיים שפונים לקהל תרבותי מוגדר, הבחנה שאינה קיימת כיום בפיצ'ר `is_english`, שמפריד רק בין אנגלית ללא אנגלית.

is_non_english_non_western - פיצ'ר בינארי המזהה סרטים שאינם באנגלית ומגיעים ממדינות שאינן בין המדינות המרכזיות בדאטה. בניתוח השגיאות ראינו שסרטים ממדינות פחות מיוצגות וסרטים עם מדינה חסרה עלולים לקבל ייצוג דומה במודל, אף שמדובר במקרים שונים. פיצ'ר זה יכול לעזור להבחין בין סרט חסר מידע לבין סרט זר או נישתי עם קהל יעד מוגדר.

שיפור פיצ'ר התקציב - כיום השתמשנו בbudget_reported כפיצ'ר בינארי בלבד, בשל ריבוי חסרים ופורמטים לא אחידים בעמודת התקציב. בעתיד ניתן להשלים נתוני תקציב ממקורות חיצוניים ולהמיר אותם לערך רציף, למשל בסקאלה לוגריתמית. כך המודל יוכל להבחין בין סרטים דלי תקציב, הפקות בינוניות והפקות גדולות, במקום לדעת רק האם התקציב דווח או לא.

Fairness Analysis - ניתוח ביצועי המודל לפי חתכים

מטרת סעיף זה היא לבחון האם המודל מציג רמת דיוק דומה עבור קבוצות שונות של סרטים. לצורך כך בחנו את ביצועי מודל ה-Random Forest לפי שני חתכים: ז'אנר הסרט ועשור יציאה. המדדים שנבחנו הם MAE ו-RMSE, בניתוח לפי עשור נכללו רק עשורים עם לפחות 100 סרטים, על מנת להבטיח מדגם מייצג.

ניתוח לפי ז'אנר :

ביצועי המודל אינם אחידים בין הז'אנרים. Action הציג את שגיאת החיזוי הגבוהה ביותר כ-9% מעל הממוצע הכללי בעוד Documentary הציג את השגיאה הנמוכה ביותר, כ-10% מתחת לממוצע. Comedy חרג אף הוא מעל הממוצע, ואילו Drama ו-Romance הציגו ביצועים טובים יחסית.

הפער בין Action ל-Documentary עשוי לנבוע מאופי הז'אנרים: Action הוא ז'אנר רחב ולא אחיד תחתיו מופיעים גם סרטי פעולה עתירי תקציב וגם הפקות עצמאיות דלות תקציב. מאחר שהמודל מקבל רק אינדיקציה בינארית לקיום תקציב ולא את ערכו, הוא אינו מצליח להבחין בין רמות הפקה שונות בתוך אותו ז'אנר. לעומת זאת, Documentary הוא קבוצה עקבית יותר מבחינת דפוסי תוכן ודירוג.

ניתוח לפי עשור יציאה :

נמצאו פערים ברורים בין תקופות שונות. סרטים משנות ה-2020 הציגו את שגיאת החיזוי הגבוהה ביותר - כ-12% מעל הממוצע הכללי - בעוד שסרטים משנות ה-1930 וה-1940 הציגו את השגיאות הנמוכות ביותר.

ממצא זה מוסבר בשני גורמים: ראשית, סרטים חדשים מהעשור האחרון שונים מהדפוסים ההיסטוריים שעליהם המודל אומן. שנית, דירוגי סרטים חדשים מתבססים על מספר קטן יחסית של מצביעים ולכן טרם התייצבו כפי שהוסבר בסעיף 5. לעומת זאת, סרטים ישנים שנשארו בדאטה הם לרוב קבוצה סלקטיבית של סרטים מוכרים ומתועדים היטב, ולכן קלים יותר לחיזוי.

הניתוח מצביע על כך שהמודל אינו מתנהג באופן אחיד בכל תתי הקבוצות. הפערים נובעים ככל הנראה משילוב של שלושה גורמים: שונות פנימית גבוהה בתוך ז'אנרים רחבים כמו Action, פיצ'רים כלליים שאינם מתארים לעומק את איכות ההפקה, וחוסר אחידות ברמת התיעוד בין סרטים שונים.

בהקשר זה, חוסר נתונים אינו רק בעיה טכנית אלא עשוי לשקף bias מובנה בדאטה: סרטים מסחריים ומוכרים נוטים להופיע עם מידע מלא יותר, בעוד שסרטים עצמאיים, זרים או נישתיים מופיעים עם מידע חלקי וביצועי המודל עליהם בהתאם חלשים יותר.

לסיכום, לא היינו מסתמכים באופן מלא על תחזיות עבור סרטי Action, סרטים מהעשור האחרון עם מידע חלקי, או סרטים עם מעט נתונים זמינים. בקבוצות אלה יש לפרש את תחזיות המודל בזהירות רבה יותר.

שימוש בכלי בינה מלאכותית

במהלך העבודה נעזרנו בכלי בינה מלאכותית, ב-Claude ו-ChatGPT ככלי עזר טכני ולשוני במספר שלבים:

1. **הבנת קוד וחומרי לימוד** - נעזרנו ב-AI לצורך העמקת ההבנה של רכיבים מורכבים מחומרי הקורס, כגון בניית Pipeline עם ColumnTransformer, שימוש ב-GridSearchCV ו-Cross Validation, מניעת Data Leakage שימוש ב-SHAP ופרשנות מדדי ביצוע.
 2. **ניתוח תוצאות ושגיאות** - התייעצנו עם AI לגבי ניתוח השגיאות הקיצוניות, השוואה בין Overprediction ל-Underprediction והסבר גרפי חשיבות הפיצ'רים.
 3. **ויזואליזציה וקוד עזר** - נעזרנו בכלים ליצירת קוד ראשוניים לגרפים ולשיפור תצוגת התוצאות. הקוד הותאם ונבדק על ידנו בהתאם לנתונים ולממצאים שהתקבלו במחברת.
 4. **Feature Engineering** - נעזרנו ב-AI לצורך חשיבה של פיצ'רים אפשריים ולבניית רשימות ראשוניות של במאים ושחקנים מוכרים. הרשימות עברו אימות אל מול מקורות חיצוניים (אתרי קולנוע) טרם השימוש בהן ולא נבנו לפי הנתונים הקיימים.
 5. **ניסוח וכתיבה אקדמית באנגלית** - נעזרנו ב-AI לשיפור ניסוח באנגלית ובעברית, כתיבת Markdown במחברת וארגון ההסברים בדוח. הניסוח הסופי נערך ונבדק על ידנו כדי לוודא שהוא משקף את הממצאים בפועל.
 6. **אופטימיזציה של טעינת נתונים** - נעזרנו ב-AI לצורך פתרון בעיית זיכרון בטעינת קבצי IMDb גדולים, כגון title.crew.tsv ו-name.basics.tsv. בעקבות ההתייעצות יישמנו קריאה בחלקים (chunks) וסינון מיידי לפי מזהי הסרטים הרלוונטיים לדאטה שלנו, במקום טעינת הקבצים המלאים לזיכרון. פתרון זה אפשר לעבד את קבצי העזר בצורה יעילה יותר ולשלב מידע על במאים ושחקנים מבלי להעמיס על סביבת העבודה.
- כל פלט שנוצר בעזרת AI נבדק מול הקוד, הגרפים והטבלאות שיצאו במחברת. ההחלטות הסופיות לגבי ניקוי הנתונים, בחירת הפיצ'רים, בחירת המודלים, פרשנות התוצאות והמסקנות התקבלו על ידנו. לכן השימוש ב-AI שימש ככלי עזר בלבד, ולא כתחליף להבנת הקוד, אימות התוצאות או קבלת ההחלטות המתודולוגיות.

מסקנות מגבלות והצעות להמשך:

בעבודה זו בחנו מודלים לחיזוי דירוג ממוצע של סרטים לפני יציאתם, על בסיס מאפיינים הזמינים מראש. מבין שני המודלים שנבחנו מודל Random Forest הניב ביצועים טובים יותר מ-ElasticNet אך הפערים בין המודלים לא היו גדולים. ניתוח השגיאות הראה כי שני המודלים מתקשים במיוחד בחיזוי סרטים הנמצאים בקצוות התפלגות הדירוגים, כלומר סרטים בעלי דירוג אמיתי נמוך מאוד או גבוה מאוד.

מניתוח חשיבות הפיצ'רים עלה כי לז'אנר הסרט יש השפעה מרכזית על החיזוי, בעיקר דרך פיצ'רים כמו genre_documentary ו-genre_horror בנוסף, ניתוח ה-Fairness Analysis הראה כי רמת הדיוק של המודל אינה אחידה בין קבוצות שונות. בפרט, המודל היה פחות מדויק עבור סרטי Action ועבור סרטים מהעשור האחרון, בעיקר כאשר המידע על הסרט חלקי.

למחקר קיימות מספר מגבלות ראשיות, חלק מהעמודות המרכזיות בדאטה, במיוחד תקציב, מדינה ושפה, כללו שיעור גבוה של ערכים חסרים או פורמטים לא אחידים. במסגרת העבודה לא בוצעה השלמה חיצונית


של ערכים אלה, ולכן המודל התבסס רק על המידע שהיה זמין בדאטה לאחר הניקוי. מגבלה זו עשויה להשפיע במיוחד על סרטים זרים, עצמאיים או נישתיים, שלעיתים מיוצגים בדאטה באמצעות מידע חלקי בלבד.

בנוסף, עמודת התקציב הכילה ערכים לא עקביים ויחידות שונות, מה שהוביל להמרתה לפיצ'ר בינארי בלבד פתרון ביניים שמגביל את כוח החיזוי.

בהמשך ניתן לשפר את המודל באמצעות השלמת ערכים חסרים ממקורות חיצוניים כגון TMDb או IMDb Pro בעיקר עבור תקציב, מדינה ושפה. עבור תקציב, ניתן להמיר את הערכים לסקאלה לוגריתמית כדי לצמצם השפעה של ערכים חריגים ולאפשר השוואה טובה יותר בין סרטים. עבור מדינה ושפה, ניתן ליצור פיצ'רים מדויקים יותר, כגון התאמה בין שפת הסרט למדינת המקור, או הבחנה בין סרטים חסרי מידע לבין סרטים זרים או נישתיים בעלי הקשר תרבותי ברור.


לסיכום, המודל מספק בסיס סביר לחיזוי מוקדם של דירוגי סרטים, אך רמת הדיוק שלו אינה אחידה בין כל סוגי הסרטים. לכן, יש לראות בתחזית המודל אינדיקציה כללית בלבד, במיוחד עבור סרטים חדשים, סרטי Action, סרטים נישתיים או סרטים שמיוצגים בדאטה באמצעות מידע חלקי.

נספח 1 - השוואת ביצועי ElasticNet ו Random Forest




נספח 2 - ניתוח חשיבות הפיצרים לכל מודל

חמשת הפיצרים בעלי המקדמים הגבוהים ביותר במודל ElasticNet



הגרף מציג את מקדמי חמשת הפיצרים המשפיעים ביותר במודל ElasticNet כל קו מייצג פיצר אחד גובה הקו מציין את עוצמת ההשפעה, וצבעו את כיוונה: ירוק = מקדם חיובי (מעלה את הדירוג החזוי) אדום = מקדם שלילי (מוריד את הדירוג החזוי). הערכים מעל הקווים הם המקדמים המדויקים.

חמשת הפיצרים החשובים ביותר במודל Random Forest :



ערכי SHAP מציגים את עוצמת וכיוון ההשפעה של כל פיצר על החזוי. כל נקודה מייצגת סרט אחד - מיקומה על ציר X מראה כמה הפיצר השפיע על הדירוג החזוי (ימנה = העלאה, שמאלה = הורדה), וצבעה מציין את ערך הפיצר (אדום = גבוה, כחול = נמוך).